

Module OCR intelligent base sur Qwen

Extraction automatique des donnees de documents de rapatriement

Element	Description
Backend API	FastAPI - endpoint POST /api/ocr/parse
Modele IA	Qwen2.5-VL-7B via LM Studio
Interface de test	Gradio
Sortie	JSON normalise pour pre-remplissage React
Evaluation actuelle	100% sur 1 document test valide

1. Presentation du module

Le module OCR intelligent automatise l'extraction de donnees depuis un document financier de rapatriement. L'objectif est de remplacer la saisie manuelle par une extraction fiable, normalisee et directement exploitable par une application web.

```
{
  "dateDosRap": "2026-06-08",
  "mntRap": 250.0,
  "typePieceBenef": 1,
  "noPieceBenef": "0004545Y"
}
```

2. Objectifs fonctionnels

- Charger un document PDF de rapatriement.
- Extraire la date de l'operation.
- Extraire le montant du rapatriement.
- Identifier le type de piece du beneficiaire.
- Extraire le numero de piece du beneficiaire.
- Retourner un JSON standardise pour une application React.
- Pre-remplir automatiquement le formulaire metier.

3. Technologies utilisees

Technologie	Role dans le projet
Python 3.11	Langage principal du backend OCR.
FastAPI	Creation de l'API REST consommable par React.
Uvicorn	Serveur ASGI pour executer l'API FastAPI.
PyMuPDF	Extraction du texte depuis les fichiers PDF.
Qwen2.5-VL-7B	Modele LLM local utilise pour aider l'interpretation des documents.
LM Studio	Execution locale du modele et exposition d'une API compatible OpenAI.
Gradio	Interface de test locale, non utilisee comme API d'integration.
React	Application cliente qui upload le PDF et pre-remplit le formulaire.

4. Architecture generale

```
Utilisateur
-> Application React
-> POST /api/ocr/parse (multipart/form-data)
-> Backend FastAPI
-> PyMuPDF + regles metier
-> LM Studio / Qwen local si necessaire
-> JSON normalise
-> Formulaire pre-rempli
```

L'API officielle d'integration est developpee avec FastAPI. Gradio reste une interface de test locale permettant de valider rapidement le comportement du module.

5. Role du modele IA

Le modele Qwen execute localement assiste l'analyse des documents lorsque le layout varie ou lorsque le texte extrait demande une interpretation. L'approche combine des regles deterministes et l'apport d'un LLM local. Cette combinaison limite les erreurs et conserve les donnees sensibles sur la machine locale.

```
LM_STUDIO_HOST=http://127.0.0.1:1234
QWEN_MODEL=qwen2.5-vl-7b
LM_STUDIO_TIMEOUT=900
```

6. Inputs et outputs

Element	Detail
Input	Fichier PDF, PNG, JPG ou JPEG envoye avec le champ form-data file.
Endpoint	POST http://localhost:8000/api/ocr/parse
Output	JSON contenant dateDosRap, mntRap, typePieceBenef et noPieceBenef.
Format date	YYYY-MM-DD
Type piece	C -> 1, S -> 4

7. Regles metier d'extraction

- dateDosRap correspond a la date de l'operation trouvee dans le document.
- mntRap correspond au montant associe a DROITS A TRANSFERT CUMULES (6), ou au plus petit montant pertinent.
- typePieceBenef vaut 1 si le document contient le code C.
- typePieceBenef vaut 4 si le document contient le code S.
- noPieceBenef correspond au code beneficiaire compose de 7 chiffres suivis d'une lettre.

8. API REST exposee

```
GET http://localhost:8000/api/health
GET http://localhost:8000/api/ocr/parse/schema
POST http://localhost:8000/api/ocr/parse
```

Exemple de requete Postman:

```
Method: POST
URL: http://localhost:8000/api/ocr/parse
Body: form-data
Key: file
Type: File
Value: Rapatriement_AVA.pdf
```

9. Integration React

```
const formData = new FormData();
formData.append("file", file);

const response = await fetch("http://localhost:8000/api/ocr/parse", {
  method: "POST",
  body: formData,
});
```

```
const data = await response.json();
```

Le JSON retourne est ensuite mappe vers les champs du formulaire: typePieceBenef, noPieceBenef, mntRap et dateDosRap.

10. Evaluation et accuracy

L'accuracy est calculee en comparant le JSON extrait avec des valeurs attendues validees manuellement. La metrique principale est l'accuracy par champ.

Accuracy = nombre de champs correctement extraits / nombre total de champs attendus

Document	Champs corrects	Total champs	Accuracy
Rapatriement_AVA.pdf	4	4	100%

Cette valeur represente l'evaluation actuelle sur un document test. Pour une evaluation scientifique plus solide, il faut constituer un dataset contenant plusieurs documents annotes.

11. Securite et confidentialite

- Les fichiers temporaires sont supprimes apres traitement.
- La taille maximale des fichiers est limitee par configuration.
- Les cle API restent cote backend et ne sont jamais exposees dans React.
- LM Studio ne doit pas etre expose directement a Internet.
- Une authentication peut etre ajoutee si l'API est exposee hors reseau local.

12. Limites et perspectives

Limites identifiees:

- PDF scanne ou image de mauvaise qualite.
- Documents fortement inclines, flous ou incomplets.
- Layouts tres differents du format attendu.
- Modele Qwen non charge dans LM Studio.

Ameliorations possibles:

- Ajouter un score de confiance par champ.
- Tester le modele sur un dataset plus large.
- Ajouter une validation humaine avant soumission.
- Gerer plusieurs operations dans un seul document.
- Ajouter une authentication JWT pour securiser l'API.

13. Conclusion

Le module OCR intelligent base sur Qwen permet d'automatiser l'extraction d'informations depuis des documents financiers de rapatriement. Il combine extraction PDF, regles metier et assistance LLM locale. L'API FastAPI POST /api/ocr/parse offre une integration simple avec React pour pre-remplir automatiquement le formulaire metier.